EduSync

Căn chỉnh đa phương thức và phân tích bài giảng luyện thi TOEIC

Đề tài

- Đầu vào: video quay màn hình, lời giảng có cả Tiếng Việt - Anh, log chat
- Đầu ra: **sổ tay học viên** (tua theo câu hỏi, chủ điểm, từ vựng, phản hồi chat)
- Môn NLP501

Thành viên thực hiện

- Phạm Đức Bình
- An Ngọc Quang
- Tạ Quang Minh
- Nguyễn Minh Châu

Vấn đề

Sau buổi học qua Online chỉ còn video dài hàng giờ và một file chat

Học viên

- Muốn xem lại đoạn chữa một câu phải tua thủ công. Thời gian xem trung vị của video bài giảng chỉ khoảng **6 phút** (Guo et al., L@S 2014); các đỉnh tua tập trung quanh chỗ chuyển cảnh (Kim et al., L@S 2014).
- Ngại hỏi lại trước lớp: sợ bị đánh giá tiêu cực (Horwitz et al., 1986).
- Lỗi sai trong chat trôi mất sau buổi học, thiếu phản hồi sửa lỗi kịp thời.

Mục tiêu của EduSync

1. Bấm một câu hỏi → video tua đến lúc cô **bắt đầu chữa** câu đó
2. Câu hỏi → **chủ điểm ngữ pháp** → đoạn giảng lý thuyết
3. Từ vựng theo bậc **CEFR**, nghĩa tiếng Việt cô giảng, audio giọng cô
4. Chat: phát hiện **lỗi điển hình của người Việt**, giải thích bằng tiếng Việt

Bài toán NLP và dữ liệu

Bốn bài toán con

1. **Căn chỉnh đơn điệu**: câu hỏi $e_k \rightarrow$ thời điểm t_k, với $t_1 < t_2 < \ldots$
2. **Liên kết** câu hỏi $\rightarrow$ chủ điểm $g \in G \cup \{\text{none}\}$
3. **Từ vựng**: lemma, bậc CEFR, nghĩa tiếng Việt lấy từ lời giảng
4. **Lỗi người học** trong chat: 6 mẫu chuyển di từ tiếng Việt

Thách thức

- Lời giảng có cả Tiếng Việt - Anh: 73% đoạn tiếng Việt, 26% tiếng Anh
- OCR nhiễu; số câu đánh lại từ 1 ở mỗi phần
- Câu hỏi và tên chủ điểm thường không có từ chung

Bài (YouTube, CC BY)	Dài	Vai trò
ECE TOEIC Starter Unit 4	58′ · 34 câu	phát triển
ECE TOEIC Starter Unit 5	58′ · 35 câu	**kiểm tra độc lập**
ECE TOEIC Starter Unit 1	65′	ASR
8 video TOEIC tiếng Việt, 6 kênh khác	3 giờ 9′ · 68 câu	**kiểm tra tổng quát hóa**

Unit 4 / Unit 5 có **một người nói** (giáo viên). Chat của Unit 4 (17 tin nhắn) là **dữ liệu mô phỏng**. Nhãn chuẩn là bản nháp do AI gán, chưa xem output hệ thống; nhóm đang kiểm tra lại với video.

Kiến trúc

Ba điểm kết hợp giữa các luồng dữ liệu (①–③)



Nghiên cứu liên quan

Công trình	Ý chính	EduSync dùng / khác gì
Anderer et al. 2024, MaViLS (arXiv 2409.16765)	Căn chỉnh video ↔ slide bằng ASR + OCR + đặc trưng hình ảnh, quy hoạch động	Không có slide gốc; căn chỉnh tới **từng câu hỏi**
Radford et al., ICML 2023 (Whisper)	ASR đa ngữ quy mô lớn, điều kiện hóa bằng văn bản đi trước	ASR lời giảng có cả Tiếng Việt - Anh; thử gợi ý từ màn hình
Peng et al., Interspeech 2023	Dùng prompt để điều khiển Whisper zero-shot	Cơ sở cho gợi ý theo ngữ cảnh màn hình
Reimers & Gurevych 2019; Wang et al. 2022/2024 (E5, mE5)	Bi-encoder câu; embedding đa ngữ	Liên kết câu hỏi tiếng Anh ↔ chủ điểm giảng bằng tiếng Việt
Bryant, Felice & Briscoe, ACL 2017 (ERRANT)	Tự động gán loại lỗi cho cặp câu gốc / câu sửa	Gán loại lỗi; nhãn kiểm chứng bằng errant 3.0.2
CEFR-J Wordlist; English Vocabulary Profile	Từ vựng phân bậc A1–C2	Từ điển 8.845 mục (CEFR-J + Octanove)

TV2 · 04:30

Nhận dạng lời giảng có cả Tiếng Việt - Anh

Cách làm

- `faster-whisper large-v3-turbo`, chế độ đa ngữ, chạy trên máy cá nhân
- Gán ngôn ngữ cho từng đoạn theo **mật độ chữ có dấu**: > 0,3 → `vi`; 0 → `en`; còn lại → `mixed`
- Thử nghiệm: lấy từ tiếng Anh trên **màn hình đang chiếu** (OCR) làm `hotwords` cho Whisper ①

Căn chỉnh câu hỏi ↔ lời giảng

Quy hoạch động đơn điệu với khẩu lệnh có xác minh ngữ cảnh

```
s(k, j) = 25·trigger + 2·|từ chung| + 3·đang_chiếu
```

- **trigger**: đoạn j nói "câu (số/thứ) N", "câu hỏi số N", "câu thứ tư"; loại "text / page / part / trang N"
- **Xác minh**: nếu 60 s sau đó không có từ nào của câu hỏi thì trigger chỉ được **2** điểm thay vì 25

```
D[k][j] = s(k,j) + max(0, max D[k′][j′]) với k′ < k, t(j′) < t(j)
```

- Tối ưu toàn cục, cho phép bỏ qua câu; sau đó **lùi mốc** về các đoạn ngay trước có chung từ với câu hỏi

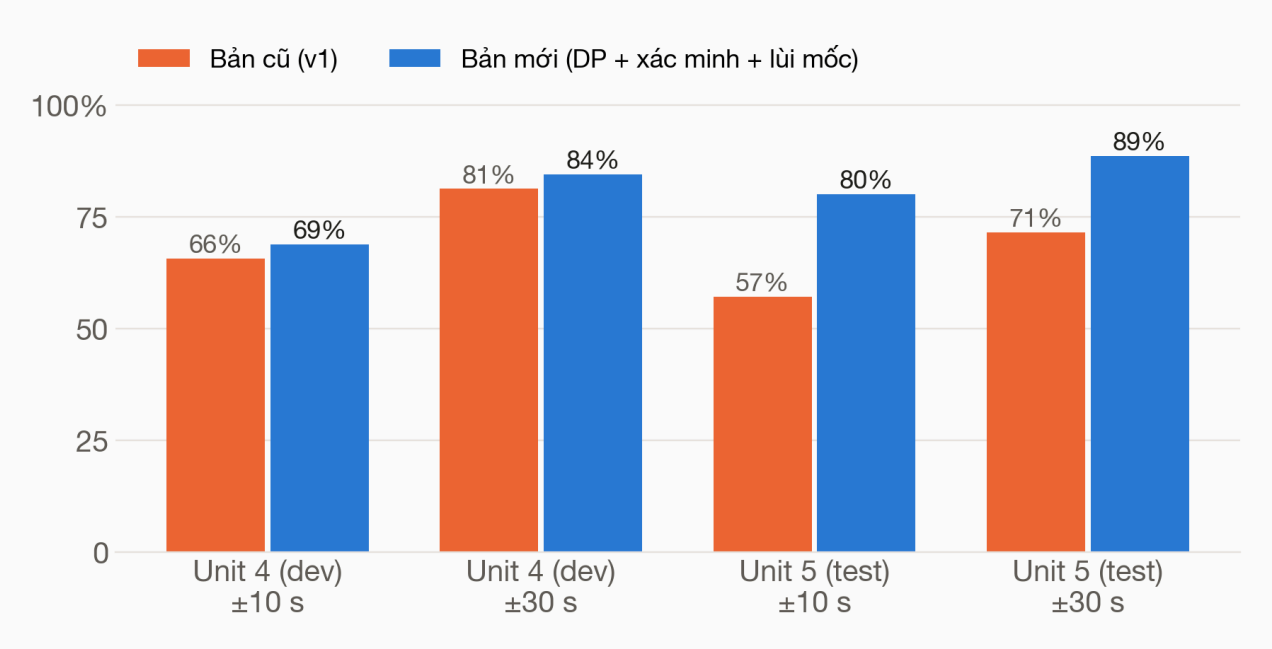
Tình huống thật ở Unit 4

Màn hình chiếu **Exercise B**, nhưng cô chữa **Exercise A trong sách** trước:

> "…chúng ta sẽ bước vào làm câu số 1." (03:09): nói về Exercise A, không có từ nào của câu B1

Bản cũ gán câu B1 vào 03:09 (lệch 216 s). Bản mới bỏ qua khẩu lệnh không được xác minh này và chọn 07:05, trong đoạn cô chữa câu B1 (lệch 21 s so với nhãn 06:45).

Kết quả căn chỉnh



Trên bài kiểm tra độc lập (Unit 5)

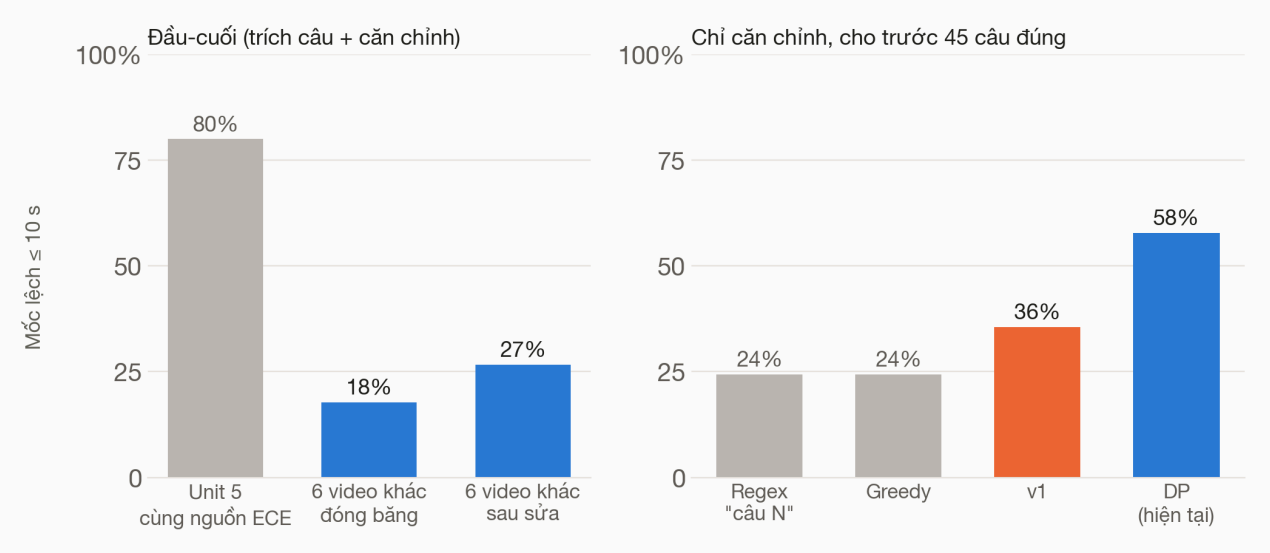
- Đúng trong ±10 s: **57% → 80%**
- Sai số trung bình: **28,5 s → 8,1 s**
- Đảo thứ tự câu: **2 → 0**

Ghi chú trung thực

- Trên cả hai bài, **DP chọn giống greedy**; phần cải thiện đến từ cách tính điểm, bước lùi mốc và cách xử lý câu không khớp
- Lỗi còn lại chủ yếu ở chỗ trống trong đoạn văn (Part 6/7): cô đọc liền cả đoạn nên khó xác định lúc bắt đầu
- Chuẩn so sánh: chỉ dùng thời điểm màn hình đạt 49% (±10 s)
- Unit 4 và Unit 5 cùng giáo viên, cùng sách → slide sau kiểm tra trên video khác

Trên video của giáo viên khác

8 video TOEIC tiếng Việt, 6 kênh YouTube (CC BY), 68 câu có nhãn; không chỉnh thuật toán theo bộ này



6 video bài giảng, 45 câu. "Đóng băng" = hệ thống trước khi xem bộ này. "Sau sửa" = `exercises.py` nhận số câu 3 chữ số (TOEIC 101–200), không còn là kiểm tra độc lập.

Kết quả

- Đầu-cuối: **18%** đúng ±10 s (Unit 5 cùng nguồn: 80%) → **80% không phải độ chính xác chung**
- Cho trước danh sách câu đúng: DP **58%**, gấp đôi greedy và regex (24%)

Vì sao sai

- **Trích câu từ màn hình** chỉ hợp slide in sẵn "N.": hỏng với bảng viết tay, bảng cuộn, câu chỉ có tranh/audio (tìm được 44% số câu)
- Giáo viên nói "câu này" thay vì "câu 116"; đọc câu hỏi tiếng Anh trước khi màn hình của câu hiện ra

Liên kết câu hỏi ↔ chủ điểm ngữ pháp

Vấn đề

"The movie was very ___ (A) move (B) moving (C) moved" ↔ *Participles as Adjectives*: không có từ chung.

Bản cũ (v1)

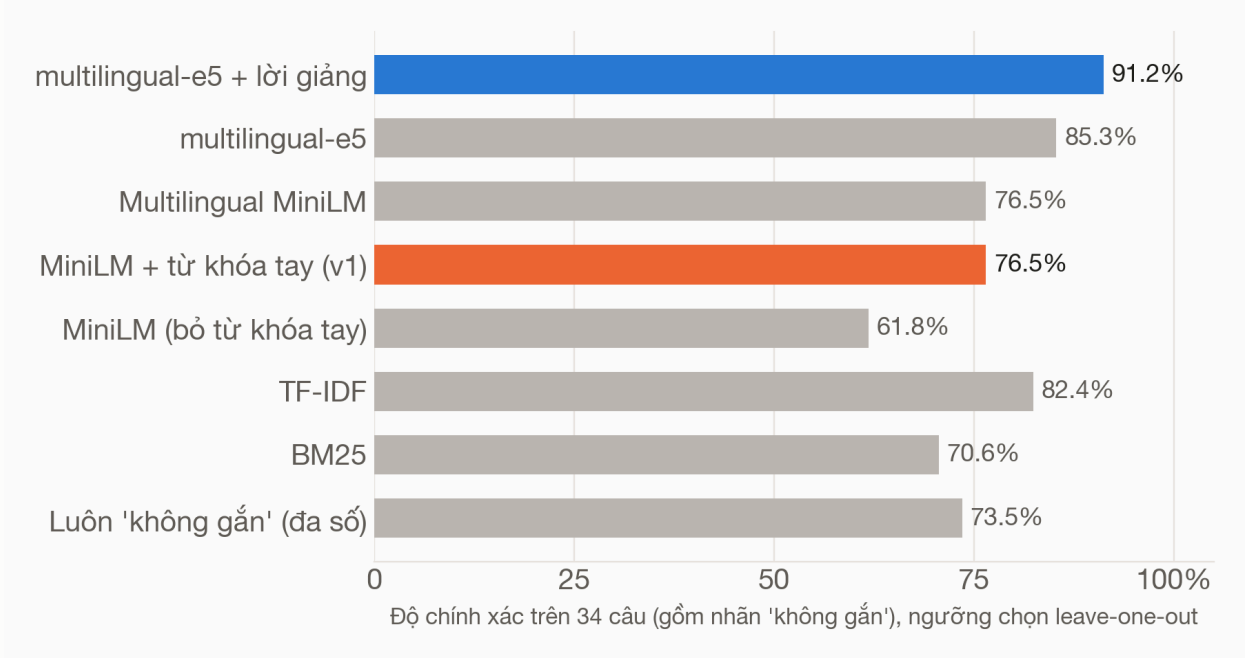
- `all-MiniLM-L6-v2`: chỉ hiểu tiếng Anh, trong khi phần giải thích chủ điểm bằng tiếng Việt
- Ghép thêm **từ khóa viết tay**, trong đó có cả từ đáp án (`central`, `luxury`, `shined`…) → **rò rỉ nhãn**
- Bỏ từ khóa: 76,5% → **61,8%**

Bản hiện tại

```
score(q, c) = ½ [cos(E(câu hỏi), E(c)) + cos(E(lời giảng khi chữa q), E(c))]
```

- E = `multilingual-e5-small` (đa ngữ, 384 chiều)
- Lời giảng ③: "*chọn động từ thêm ing hay thêm ed để làm tính từ*", "*công thức nhờ vả*"
- Gắn nếu score ≥ 0,835, ngược lại là "không gắn" (câu từ vựng / đọc hiểu)
- Không dùng từ khóa viết tay; dự phòng bằng TF-IDF

Kết quả liên kết chủ điểm (Unit 4, 34 câu)



Đầu ra thực tế trong demo

	v1	Hiện tại
Độ chính xác	58,8%	**91,2%**
Badge đúng (precision)	39,1%	**90,0%**
Câu có chủ điểm được gắn (recall)	66,7%	**75,0%**
Số badge	23	10

22/34 câu là từ vựng / đọc hiểu nên "luôn không gắn" đã đạt 73,5%. Mô hình và ngưỡng được chọn trên chính 34 câu này, và một số ví dụ chủ điểm do Gemini sinh chép gần nguyên câu hỏi, nên kết quả có thể lạc quan; chưa có tập kiểm tra độc lập cho bài toán này.

Trích xuất chủ điểm và từ vựng

Chủ điểm: Gemini (JSON mode) + neo mốc

Gemini chỉ thấy khoảng 30 đoạn lấy mẫu nên mốc thời gian nó trả về là đoán. Neo lại vào cửa sổ lời giảng giống chủ điểm nhất (e5):

Chủ điểm	Nhãn	v1	Hiện tại
Participles	00:24	15:06	**00:44**
Causative	15:46	17:14	**15:38**
Passive / require that	13:16	55:02	**13:18**
Noun modifiers	07:20	08:13	**07:35**

Sai số trung bình: **882,5 s → 11,2 s**. Khi không có mạng: dùng bảng chủ điểm TOEIC và tìm từ khóa trong lời giảng.

Từ vựng (`vocab.py`)

- Lemma 2 lớp (bảng bất quy tắc + bỏ hậu tố)
- Tra **CEFR-J + Octanove** (8.845 mục)
- Lọc từ tiếng Việt trùng mặt chữ tiếng Anh: *hay, con, cho, ra, nam, sau…*
- Lấy nghĩa từ lời giảng: "X là / nghĩa là …"

Unit 4: 80 từ (A1 26 · A2 26 · B1 18 · B2 9 · C1 1); 52 từ có nghĩa tiếng Việt; 79 clip audio 0,7–2,2 s giọng cô

Độ đúng của nghĩa và audio chưa được đánh giá.

Phát hiện lỗi người học trong chat

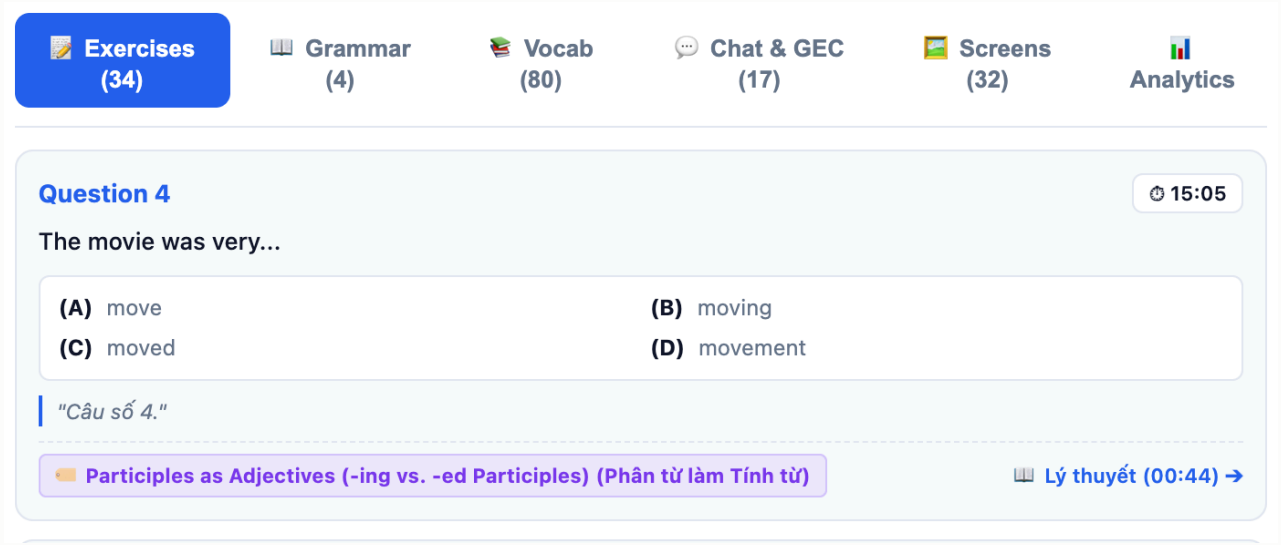
Luật cho 6 mẫu lỗi chuyển di từ tiếng Việt; nhãn loại lỗi kiểm chứng bằng errant 3.0.2

Nhóm	Ví dụ → sửa	Loại ERRANT	Recall
Thừa *be*	I am agree → I agree	U:VERB:TENSE	50%
-ing / -ed	the movie was moved → moving	R:VERB:FORM	88%
Nhờ vả	have my car repair → repaired	R:VERB:FORM	75%
Modal + to	should to increase → should increase	U:VERB:FORM	100%
Hòa hợp chủ vị	it make → it makes	R:VERB:SVA	63%
Thiếu *do*	Why we use…? → Why do we use…?	M:VERB:TENSE	43%

Tập độc lập 70 câu (viết riêng, không xem luật): v1 P 90% / R 21% → hiện tại **P 100% / R 72,7% / F1 84,2%**

Không phải mô hình GEC tổng quát: bỏ qua mọi lỗi ngoài 6 nhóm. Tên học viên được ẩn danh thành S1…SN. Trước khi chốt, tập 70 câu được xem một lần để sửa 3 lỗi cài đặt.

Demo



Bên trái của giao diện là video + transcript chạy theo; bên phải là danh sách câu hỏi với badge chủ điểm.

1. Tab **Exercises**: bấm Question 4 (*The movie was very…*) → video tua đến 15:05, lúc cô bắt đầu chữa
2. Badge *Participles* → **Lý thuyết (00:44)**: tua về đoạn giảng đầu giờ
3. Tab **Vocab**: lọc theo CEFR, nghe audio
4. Tab **Chat & GEC**: lỗi, câu sửa, giải thích tiếng Việt

Chạy: `python demo/prepare.py --lesson lessons/ece-toeic-starter-u4` rồi `cd demo && python -m RangeHTTPServer 8000`. Có video quay sẵn để dự phòng.

Hạn chế và hướng phát triển

Hạn chế

- Chỉnh trên 1 giáo viên: video của kênh khác chỉ đúng **18%** (±10 s)
- Trích câu từ màn hình cần slide in sẵn số câu
- Nhãn chuẩn do AI gán, chưa được người kiểm tra hết
- Chat là dữ liệu mô phỏng
- Chưa đo WER; gợi ý từ màn hình chưa chứng minh được hiệu quả
- Ngưỡng liên kết chủ điểm chọn trên tập phát triển
- Phát hiện lỗi dựa trên luật, chỉ 6 mẫu

Hướng phát triển

- Nhận câu hỏi từ chữ viết tay / bảng cuộn và chỗ giáo viên đang khoanh trên màn hình
- Sửa 5 clip ASR → WER thật cho 3 cấu hình
- Thu bản ghi lớp thật: tương tác giữa giáo viên và học viên trong lớp thực tế
- Tập kiểm tra độc lập cho liên kết chủ điểm (Unit 5)
- Phát hiện lỗi bằng mô hình sửa câu (seq2seq / LLM) + errant để gán loại
- Mở rộng sang bài giảng IELTS

Kết luận

1. **Căn chỉnh câu hỏi ↔ lời giảng** với khẩu lệnh có xác minh ngữ cảnh: **80%** câu đúng trong ±10 s trên bài kiểm tra cùng nguồn (v1: 57%); trên video của 6 kênh khác chỉ **18%**, do bước trích câu từ màn hình
2. **Lời giảng làm tín hiệu liên kết chủ điểm** (e5 đa ngữ): **91,2%** trên 34 câu (v1: 58,8%), không dùng từ khóa viết tay
3. **Đánh giá tái lập được**: nhãn, script, baseline; số liệu chưa đo được ghi rõ là chưa đo

Tài liệu

- `docs/10_evaluation_results.md` : toàn bộ số liệu
- `eval/run_all.py` : tái tạo số liệu
- `demo/` : sổ tay học viên tương tác

Hỏi – đáp